

Reconhecimento de Padrões

Análise de Componentes Independentes

Prof. George von Borries
Departamento de Estatística
Universidade de Brasília

1 - 2024




Objetivos

- **Análise de Componentes Independentes (ICA)**
projeções/direções independentes e não normais.
- **Busca de Projeção (PP) - PROJECTION PURSUIT**
projeções/direções não normais.
- **Análise de Componentes Principais (PCA)**
projeções/direções não correlacionadas.
- PCA com componentes normalmente distribuídas \Rightarrow ICA.
- Semelhante a **Análise Fatorial**, porém com possíveis relações não lineares, diferentes suposições e não busca redução de dimensionalidade.



Motivação

THE COKTAIL-PARTY



Problema da fala. Journée (2008)

$$\mathbf{x}_1 = a_{11}\mathbf{s}_1 + a_{12}\mathbf{s}_2$$

$$\mathbf{x}_2 = a_{21}\mathbf{s}_1 + a_{22}\mathbf{s}_2$$

$$\mathbf{s}_1 = w_{11}\mathbf{x}_1 + w_{12}\mathbf{x}_2$$


$$\mathbf{s}_2 = w_{21}\mathbf{x}_1 + w_{22}\mathbf{x}_2$$



Motivação

Geometricamente

- Estimar \mathbf{A} , \mathbf{W} , \mathbf{S} ;
- Encontrar \mathbf{W} que forneça fontes o mais independentes possível;
- \mathbf{W} ótimo maximiza a não-gaussianidade de \mathbf{WX} .




Extração de uma fonte (S_1) a partir de três misturas. Stone (2004)



Motivação

ICA em EEG



Representação das fontes no cérebro. Rajapakse, Cichocki e A. Sanchez (2002)

- Sinais altamente correlacionados.
- Fontes estatisticamente independentes.
- Quantidade de fontes?
- Localização das fontes?



Modelos

- 1 Modelo ruidoso: $\mathbf{X} = f(\mathbf{S}) + \mathbf{e}$
- 2 Modelo sem ruído: $\mathbf{X} = f(\mathbf{S})$
- 3 Modelo linear e estacionário: $\mathbf{X} = f(\mathbf{S}) = \mathbf{AS}$
- 4 Modelo temporal ou indexado: $\mathbf{X}(t) = \mathbf{AS}(t)$
(ex. sinais de áudio/música, EEG, MEG)

Em geral,

- $\{\mathbf{s}_j\}$, $j = 1, \dots, m$, são variáveis latentes independentes e não normais (ou no máximo com uma componente normal),
- $f : \mathbb{R}^m \rightarrow \mathbb{R}^p$,
- $E(\mathbf{e}) = \mathbf{0}$,
- $E(\mathbf{S}) = \mathbf{0}$,
- $\text{Cov}(\mathbf{S}) = \mathbf{I}_m$.



Identificabilidade do Modelo

A identificabilidade do modelo sem ruído pode ser assegurada se

- 1 Todas as componentes independentes s_j , com possível exceção de uma componente, são não gaussianas;
- 2 O número m de misturas observadas for igual ou superior ao número k de componentes independentes;
- 3 A matriz \mathbf{A} for de posto completo.

Pré-processamento

- Consiste em centralizar e “branquear” as variáveis.
- Seja $\mathbf{x} = (x_1, \dots, x_p)^T$, com $E(\mathbf{X}) = \boldsymbol{\mu}$ e $\text{cov}(\mathbf{X}) = \boldsymbol{\Sigma}$,
 - obter a SVD de $\boldsymbol{\Sigma}$, i.e., $\boldsymbol{\Sigma} = \mathbf{U}\mathbf{D}\mathbf{U}^T$
 - Calcular $\mathbf{X} \leftarrow \mathbf{D}^{-1/2}\mathbf{U}^T(\mathbf{X} - \boldsymbol{\mu})$, que corresponde a obter a PCA dos dados centralizados e fazer cada PC com variância unitária.



Aplicações

- Separação cega de fontes: EEG, ECG, MEG, Processamento de sons e imagens;
- Extração de características;
- Estimação de densidades;
- Regressão;
- Estudos em economia, psicologia, ciências sociais.

Características adicionais

- A ordem das ICs não pode ser determinada: $\mathbf{X} = \mathbf{AS} = \mathbf{AP}^{-1}\mathbf{Ps}$.
- A variância e o sinal das ICs não podem ser determinados:

$$\mathbf{X} = \sum_j \left(\frac{1}{\lambda} a_j \right) (s_j \lambda)$$

Estipula-se, portanto, variâncias unitárias às ICs.

- Multiplicar uma IC por -1 não provoca mudanças em $\mathbf{X} = \mathbf{AS}$.



Estimação

Método ICA = Função Objetivo (contraste) + Algoritmo de Otimização

Funções Objetivo podem estimar todo o modelo (MULTI-UNIT CONTRAST FUNCTIONS) ou uma componente por vez (ONE-UNIT CONTRAST FUNCTIONS)

- Máxima verossimilhança
- Maximização da não-gaussianidade

(a) Curtose: $k = E(x^4) - 3[E(x^2)]^2$

(b) Negentropia: $J(\mathbf{x}) = H(\mathbf{x}_{gaussiana}) - H(\mathbf{x})$, sendo
 $H(\mathbf{x}) = - \int f(\mathbf{x}) \log f(\mathbf{x}) d\mathbf{x}$ a Entropia Diferencial.

- Cancelamento de correlações não lineares
- Critério de PCA não linear
- Cumulantes de ordem superior

Cumulantes são constantes da expansão de $\log \hat{f}(t)$ numa Série de Taylor, em que $\hat{f}(t) = E\{\exp(itx)\}$ é a função característica de uma variável aleatória (centralizada) x . A expansão será então,

$$\log \hat{f}(t) = k_1(it) + k_2(it)^2/2 + \dots + k_r(it)^r/r! + \dots$$

e k_r são as cumulantes. Exemplos: $k_1 = E(x)$; $k_2 = E(x^2)$; $k_3 = E(x^3)$.
A curtose é uma cumulante de quarta ordem.



Estimação

Método ICA = Função Objetivo (contraste) + Algoritmo de Otimização

Algoritmos indicam como a função objetivo escolhida será otimizada.

- FastICA¹: algoritmo neural (paralelo e distribuído)

Observação: ICASSO é um algoritmo para investigar a estabilidade das estimativas obtidas por FastICA.

- Maximização da verossimilhança
- Maximização da negentropia
- Ortogonalização de vetores

¹Ver Izenman (2008).




Exemplo: separação de ritmos cardíacos de mãe e bebê.



Ritmos cardíacos obtidos de uma gestante (Izenman, 2008).



Exemplo: utilizando algoritmo FastICA no R



Curvas **vermelhas** (IC2, IC3, IC4, IC6) refletem o ritmo cardíaco da mãe;
Curvas **azuis** (IC5, IC8) refletem o ritmo cardíaco acelerado do feto;
Curva **roxa** (IC1) provavelmente reflete um componente respiratório;
curva **preta** (IC7) reflete ruído.



Referências

- Hyvärinen., A. (1999) Survey on Independent Component Analysis. *Neural Computing Surveys*, 2, 94-128.
- Izenman, A.J. (2008) *Modern Multivariate Statistical Techniques: Regression, Classification, and Manifold Learning*. Springer.
- Stone, J.V. (2004) *Independent Component Analysis. A Tutorial Introduction*. The MIT Press.
- Kock, I. (2014) *Analysis of Multivariate High-Dimensional Data*. Cambridge.

