

Critérios para Discriminação de Duas Classes

2 Critério de Fisher

- Este critério procura a maior separação possível entre as classes através de uma combinação linear das variáveis.
- Considere ω_1 com n_1 pontos e ω_2 com n_2 pontos. Os vetores de médias de cada classe são

$$\mathbf{m}_i = \frac{1}{n_i} \sum_{n \in \omega_i} \mathbf{x}_i \quad (n = n_1 + n_2)$$

- A forma mais simples de separar as classes é escolher um vetor de projeção \mathbf{w} que maximiza a distância entre as médias \mathbf{m}_1 e \mathbf{m}_2 , i.e., $\max \mathbf{w}^T (\mathbf{m}_2 - \mathbf{m}_1)$.
- Para restringir a magnitude de \mathbf{w} , fazemos \mathbf{w} com comprimento unitário, i.e., $\sum_i w_i^2 = 1$.



- O critério de Fisher maximiza a razão das variâncias entre e dentro das classes, obtida pela projeção \mathbf{w} , i.e.,

$$J_F = \frac{\|\mathbf{w}^T(\mathbf{m}_2 - \mathbf{m}_1)\|^2}{\mathbf{w}^T \mathbf{S}_w \mathbf{w}} = \frac{\mathbf{w}^T \mathbf{S}_B \mathbf{w}}{\mathbf{w}^T \mathbf{S}_w \mathbf{w}}$$

em que

$$\mathbf{S}_w = \frac{1}{n-2} (n_1 \hat{\Sigma}_1 + n_2 \hat{\Sigma}_2)$$



Nota: $\hat{\Sigma}_i$ é a estimativa de máxima verossimilhança da matriz de covariância da classe ω_i .

- A solução para \mathbf{w} que maximiza J_F é obtida através da diferenciação de J_F em relação a \mathbf{w} e igualando a zero, resultando em

$$\frac{2\mathbf{w}^T(\mathbf{m}_2 - \mathbf{m}_1)}{\mathbf{w}^T \mathbf{S}_w \mathbf{w}} \left\{ (\mathbf{m}_2 - \mathbf{m}_1) - \frac{\mathbf{w}^T(\mathbf{m}_2 - \mathbf{m}_1)}{\mathbf{w}^T \mathbf{S}_w \mathbf{w}} \mathbf{S}_w \mathbf{w} \right\} = 0.$$

- O critério de Fisher não fornece uma regra de alocação, mas apenas uma projeção em que a discriminação das classes é mais fácil de ser realizada.





Esquerda: projeção com superposição das classes. Direita: projeção segundo critério de Fisher. (Bishop, 2006)



- O critério de Fisher não fornece uma regra de alocação, mas apenas uma projeção em que a discriminação das classes é mais fácil de ser realizada.
- Para obter um critério de alocação precisamos especificar um limite (*threshold*) w_0 e alocar \mathbf{x} to ω_1 se

$$\mathbf{w}^T \mathbf{x} + w_0 > 0$$

Exemplo de critério alocação

Considere que os dados são normalmente distribuídos e com $\Sigma_1 = \Sigma_2$.

Alocar \mathbf{x} a ω_1 se $\mathbf{w}^T \mathbf{x} + w_0 > 0$ tal que

$$\mathbf{w} = \mathbf{S}_w^{-1}(\mathbf{m}_1 - \mathbf{m}_2) \text{ e}$$

$$w_0 = -\frac{1}{2}(\mathbf{m}_1 + \mathbf{m}_2)^T \mathbf{S}_w^{-1}(\mathbf{m}_1 - \mathbf{m}_2) - \log \left(\frac{p(\omega_2)}{p(\omega_1)} \right)$$

Observação: utilizamos normalidade para especificar w_0 e obter uma solução ótima. No caso de não normalidade, a solução não é necessariamente ótima.



Critérios para Discriminação de Duas Classes

3 Critério de Mínimos Quadrados

- Este critério utiliza todos os dados da amostra para encontrar uma solução para a qual

$$\boldsymbol{\nu}^T \mathbf{y}_i = t_i$$

é satisfeita para constantes positivas t_i .

- Lembre que $\mathbf{y}_i^T = (1, \mathbf{x}_i^T)$ para $\mathbf{x}_i \in \omega_1$ e $\mathbf{y}_i^T = (-1, -\mathbf{x}_i^T)$ para $\mathbf{x}_i \in \omega_2$.
- A solução é obtida por mínimos quadrados, i.e., minimizando

$$J_S = \|\mathbf{Y}\boldsymbol{\nu} - \mathbf{t}\|^2.$$

- De Análise de Regressão, se $\mathbf{Y}^T \mathbf{Y}$ é não singular,

$$\boldsymbol{\nu} = (\mathbf{Y}^T \mathbf{Y})^{-1} \mathbf{Y}^T \mathbf{t}.$$

- Outra solução para $\boldsymbol{\nu}$, minimizando J_S é

$$\boldsymbol{\nu} = \mathbf{Y}^- \mathbf{t},$$

em que \mathbf{Y}^- é a pseudo-inversa (ou inversa generalizada) de \mathbf{Y} .





- A inversa generalizada \mathbf{A}^- pode ser obtida da decomposição em valores singulares de \mathbf{A} .

Decomposição em Valores Singulares (SVD)

- Uma matriz $\mathbf{A}_{n \times d}$ (valores reais) pode ser sempre escrita como $\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^T = \sum_{i=1}^r \lambda_i \mathbf{u}_i \mathbf{v}_i^T$ em que
 - r é o posto da matriz \mathbf{A} ;
 - \mathbf{U} é uma matriz de colunas ortonormais contendo n autovetores da matriz $\mathbf{A}\mathbf{A}^T$ (“left singular vectors”);
 - \mathbf{V} é uma matriz de colunas ortonormais contendo d autovetores da matriz $\mathbf{A}^T\mathbf{A}$ (“right singular vectors”);
 - \mathbf{D} é uma matriz $n \times d$ diagonal com $\sqrt{\lambda_i}$ em que λ_i 's ($\min\{n, d\}$) são os maiores autovalores de $\mathbf{A}\mathbf{A}^T$ ou $\mathbf{A}^T\mathbf{A}$, chamados de valores singulares.
- A inversa generalizada será $\mathbf{A}^- = \mathbf{V}\mathbf{D}^{-1}\mathbf{U}^T = \sum_{i=1}^r \frac{1}{\lambda_i} \mathbf{v}_i \mathbf{u}_i^T$.
- Propriedades:
 - $\mathbf{A}\mathbf{A}^-$ e $\mathbf{A}^-\mathbf{A}$ são simétricas;
 - $\mathbf{A}\mathbf{A}^-\mathbf{A} = \mathbf{A}$;
 - $\mathbf{A}^-\mathbf{A}\mathbf{A}^- = \mathbf{A}^-$.





O critério de mínimos quadrados é fortemente influenciado por *outliers*. Linha rosa indica limite obtido por mínimos quadrados e linha verde por regressão logística.
(Bishop, 2006)

- Se $t_i = t_1$ (constante) para todo $\mathbf{x}_i \in \omega_1$ e $t_i = t_2$ (constante) para todo $\mathbf{x}_i \in \omega_2$, a solução de mínimos quadrados corresponde ao discriminante de Fisher.
- Observação: usual fazer $t_1 + t_2 \neq 0$.




Algoritmos para 3 ou mais Classes



Ideias Gerais: considere $c > 2$ classes para classificar.

- 1 **Uma classe contra as demais:** utiliza $c - 1$ classificadores e para cada um deles resolve o problema de separação de pontos de uma classe ω_i ($i = 1, \dots, c$) e os pontos que não pertencem a esta classe.

Problema: pode gerar regiões no espaço com pontos que não possuem uma classe definida.




(Bishop, 2006)



- 2 **Pares de classes:** utiliza $c(c - 1)/2$ discriminantes binários para comparar todos os possíveis pares de classes.

Problema: número muito grande de comparações quando temos muitas classes. Também pode gerar regiões no espaço com pontos que não possuem uma classe definida.



(Bishop, 2006)




3 Discriminantes para c funções lineares:

- Função: $y_i(\mathbf{x}) = \mathbf{w}_i^T \mathbf{x} + w_{i0}$
- Alocar o ponto \mathbf{x} a classe ω_i se $y_i(\mathbf{x}) > y_j(\mathbf{x})$ para todo $i \neq j$ em $\{1, \dots, c\}$.
- O limite (*boundary*) será dado por $y_i(\mathbf{x}) = y_j(\mathbf{x})$ e corresponde ao hiperplano definido por

$$(\mathbf{w}_i - \mathbf{w}_j)^T \mathbf{x} + (w_{i0} - w_{j0}) = 0.$$

- As regiões definidas pelos discriminantes são conectadas e convexas.



Regiões convexas: Seja $0 \leq \lambda \leq 1$. Então
 $y_k(\hat{\mathbf{x}}) = \lambda y_k(\mathbf{x}_A) + (1 - \lambda) y_k(\mathbf{x}_B)$. (Bishop, 2006)

- Webb e Copsey (2011) descrevem os algoritmos de Fisher e Mínimos Quadrados para o caso de $c > 2$ classes.

